

人工智慧運算架構與演進趨勢

AI Compute Architecture and Evolution Trends

梁伯嵩 Bor-Sung Liang

bs.liang@mediatek.com

bsliang@gmail.com

2026. 8. 20

人工智慧運算 七層架構

AI 應用

Layer 7

應用層

Application Layer

- Provides services for users, autonomous systems, robots, and edge devices. Ensures reliable operation, integration with infrastructures (information, financial, and logistics flows), and user interaction.

AI 代理功能

Layer 6

協調層

Orchestrator Layer

- Coordinates and manages multiple AI agents, allocating resources, monitoring performance, and ensuring collaborative operation. Provides evaluation, lifecycle management, and orchestration of complex functions.

神經網路功能

Layer 5

代理層

Agent Layer

- Transforms LLMs into autonomous agents with memory, planning, reasoning, tool use, and interaction capabilities. Supports inter-agent collaboration (e.g., Agentic Swarms) via secure communication protocols.

神經網路功能

Layer 4

情境層

Context Layer

- Prepares and structures context for neural networks, including prompts, multimodal inputs, reasoning chains, and external data. Optimized through *context engineering* to balance performance and resource efficiency.

Tokens

Layer 3

神經網路層

Neural Network Layer

- Defines the core architecture (e.g., Transformer, Diffusion) and techniques (pre-training, MoE, LoRA, RAG, pruning, sparsity, precision).

運算基礎架構

Layer 2

連結層

Link Layer

- Provides System-level hardware/software integration enabling Scale-Up, Scale-Out, and Scale-Across computing

Layer 1

實體層

Physical Layer

- Foundation elements of AI compute: semiconductor ICs (GPU, CPU, DSP, ASICs), high-speed interconnects, memory, storage, power delivery, and cooling infrastructure.

AI 應用

Layer 7 應用層 Application Layer

AI 代理功能

Layer 6 協調層 Orchestrator Layer

Layer 5 代理層 Agent Layer

神經網路功能

Layer 4 情境層 Context Layer

Tokens

Layer 3 神經網路層 Neural Network Layer

大語言模型

Layer 2 連結層 Link Layer

基礎建設

Layer 1 實體層 Physical Layer

半導體、晶片

能源

大腦

思考與學習

身體

神經系統


循環系統

器官

產生身體運作的能量

消化系統產生能量


PIC: Google Nano Banana



表現出來的能力
受到 Context Memory 影響



學習到的內容
儲存在神經網路內的參數



天生資質與後天培養
先天能力與教育栽培

AI 應用

Layer 7 應用層 Application Layer

AI 代理功能

Layer 6 協調層 Orchestrator Layer

Layer 5 代理層 Agent Layer

神經網路功能

Layer 4 情境層 Context Layer

Tokens

Layer 3 神經網路層 Neural Network Layer

運算基礎架構

Layer 2 連結層 Link Layer

Layer 1 實體層 Physical Layer



駕馭工程 Harness Engineering
迴圈工程 Loop Engineering
圖結構工程 Graph Engineering
長期自主循環工程 Long-Horizon Loop Engineering

PIC: Google Nano Banana

AI 應用

Layer 7 應用層 Application Layer

Layer 6 協調層 Orchestrator Layer

Layer 5 代理層 Agent Layer

Layer 4 情境層 Context Layer

Tokens

Layer 3 神經網路層 Neural Network Layer

Layer 2 連結層 Link Layer

Layer 1 實體層 Physical Layer



整合
不同職能與不同專業的
AI 代理
創造高性能團隊

PIC: Google Nano Banana

AI 應用

Layer 7

應用層 Application Layer

AI 代理功能

Layer 6

協調層 Orchestrator Layer

Layer 5

代理層 Agent Layer

神經網路功能

Layer 4

情境層 Context Layer

Tokens

Layer 3

神經網路層 Neural Network Layer

運算基礎架構

Layer 2

連結層 Link Layer

Layer 1

實體層 Physical Layer

人工智慧代理
Agentic AI



實體人工智慧
Physical AI



- 成熟的人工智慧代理 與 實體人工智慧
創造高價值應用
- 釋放前所未有的生產力
推動文明更上一層樓

人工智慧運算 七層架構

(Bor-Sung Liang, 2025/8)

AI
應用

Layer 7

應用層 Application Layer


AI
代理
功能

Layer 6

協調層 Orchestrator Layer

Layer 5

代理層 Agent Layer



神
經
網
路
功
能

Layer 4

情境層 Context Layer

Tokens

Layer 3

神經網路層 Neural Network Layer

運
算
基
礎
架
構

Layer 2

連結層 Link Layer

Layer 1


實體層 Physical Layer

AI 5-Layer Cake

(Jensen Huang, 2026/3)



應用 (Applications)




模型 (Models)



基礎設施 (Infrastructure)



晶片 (Chips)



能源 (Energy)

AI
應用

Layer 7

應用層 Application Layer

AI
代理
功能

Layer 6

協調層 Orchestrator Layer

神
經
網
路
功
能

Layer 5

代理層 Agent Layer

Layer 4

情境層 Context Layer

Tokens

Layer 3

神經網路層 Neural Network Layer

Layer 2

連結層 Link Layer

Layer 1

實體層 Physical Layer

人工智慧運算硬體

- 量變造成質變
- 每七個月成長一倍，尚在加速中
- 從地球到太空

不同種類的 AI 運算硬體

邊緣AI 運算 | Edge AI Processor

- 提供邊緣設備的智慧 AI 功能
- 晶片除了 AI 運算，包含多樣複雜功能
- 豐富的無線通訊功能
- 電池供電
- 優先考慮高能源效率


~10W



AI 資料中心 | Data Center AI ASIC

- 適用於高效能運算主要
- 專用於AI 計算，由面積密集型計算電路組成
- 高速有線連接，支援資料中心擴展
- 外部供應龐大電力與散熱能力
- 優先考慮高運算性能

~1000W




不同種類的 AI 運算硬體

邊緣AI 運算 | Edge AI Processor



數十億設備 包含 AI 晶片


AI 資料中心 | Data Center AI ASIC



~100,000s Chips

數十萬顆 AI晶片集中於資料中心

用於人工智慧訓練的GPU叢集大小




Frank Helms (AMD), "The Hot Chip is a Rack"(AI Literally Demands we Think Outside the Box), AI Rack Tutorial , HotChips 2025

Scale-Up 垂直擴展

晶粒 (封裝前)
Chip (Die)

晶片 (封裝後)
Chip (Package)


(運算節點)
Compute Node



Scale-Out 橫向擴展

資料中心
Data Center

多個資料中心整合 (跨域擴展)
Multiple Data Center (Scale-Across)



Scale-Up 垂直擴展

晶粒 (封裝前)
Chip (Die)

晶片 (封裝後)
Chip (Package)

(運算節點)
Compute Node

先進
製程

先進
封裝

高速連結
垂直擴展網路

Advanced
Semi.
Process

Advanced
Package

Scale-Up
Network

Scale-Out 橫向擴展

資料中心
Data Center

多個資料中心整合 (跨域擴展)
Multiple Data Center (Scale-Across)

高速連結
橫向擴展網路

高速連結
跨域擴展網路

Scale-Out
Network


Scale-Across
Network

人工智慧運算 不僅是需要 先進半導體製程
更需要複雜的系統級工程設計整合

Data Center 規模成長快速


AI data centers ranked by compute

For comparison, xAI trained their Grok 3 model with 80K H100 GPUs.



Source: Epoch AI

地球能源有限 成為未來運算瓶頸




Source: SIA, SRC (Semiconductor Research Corporation), The Decadal Plan for Semiconductors

群益金鼎證券股份有限公司 ethan.zhuang@capital.com.tw 於 2026/08/21 07:43:37 下載

群益金鼎證券股份有限公司 版權所有。本資料僅供報名學員學習使用，未經授權轉載、散布或商業利用，將追究法律責任

太空資料中心成為新議題

- Elon Musk (2026/3): 1 TW Space Data Center
- 資料中心半導體與電力不足，每年僅增加 20GW
- 太空資料中心目標：1 TW (=1000 GW)
- AI Sat
 - 目前 100KW → 約需要 1000萬顆衛星
 - 未來 1MW → 約需要 100萬顆衛星
- TeraFab 晶圓廠
 - 邊緣訊算與推理最佳化 晶片 (自駕車、機器人)
 - 太空資料中心使用的高功率晶片 (太空衛星)
- 機器人
 - 預估未來機器人的產量，會是汽車的 10~100倍
 - 汽車年產約1億台, 人形機器人約在 10億~100億台



未來 AI 運算設計趨勢

10^{-6}

10^{-3}

10^0

10^3

10^6

10^9

10^{12}

μW

mW

W

KW

MW

GW

TW

半導體製程




晶片設計



資料中心機櫃設計

太空資料中心衛星群設計



AI 應用

Layer 7

應用層 Application Layer

AI 代理功能

Layer 6

協調層 Orchestrator Layer

Layer 5

代理層 Agent Layer

神經網路功能

Layer 4

情境層 Context Layer

Tokens

Layer 3

神經網路層 Neural Network Layer

運算基礎架構

Layer 2

連結層 Link Layer

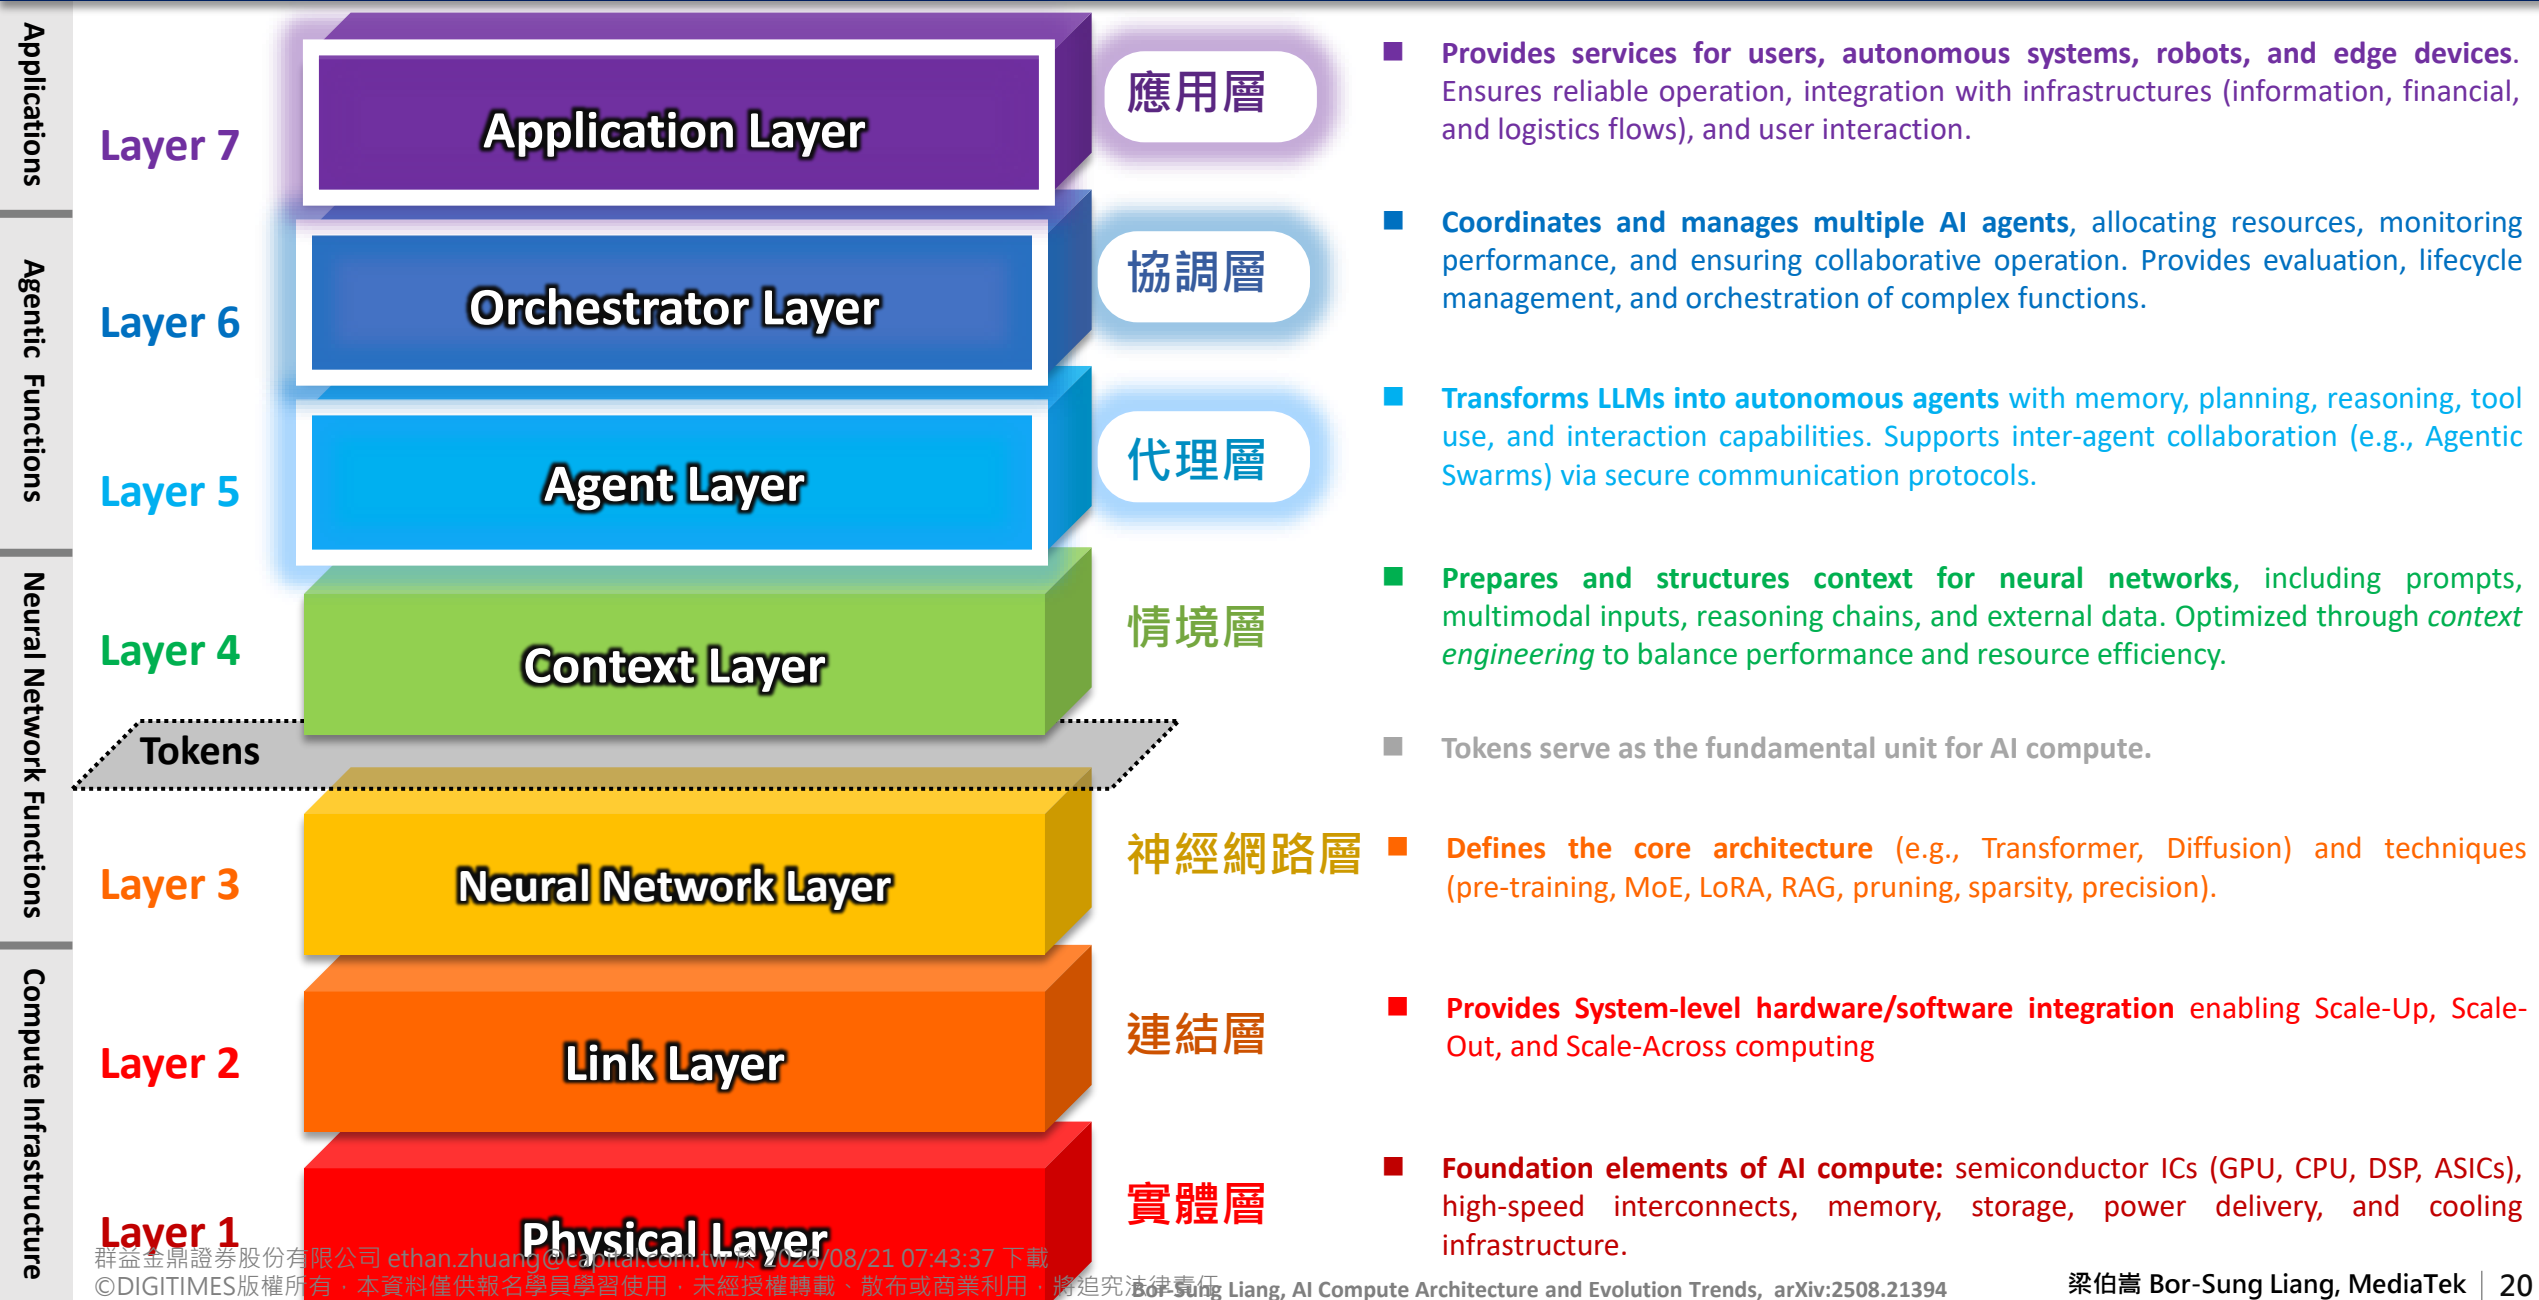
Layer 1


實體層 Physical Layer

AI 人工智慧

- 從實驗室邁向大規模應用
- 逼近 AGI 的臨界點
- 已有創造經濟效益能力

7-Layer Model for AI Computing Architecture










學習完整知識內容

歸納知識體系並理解

整理知識重點


強大的工具
提升能力

防護措施
確保安全保障



Loop Engineering


是一種設計自動化回饋循環的方法，
讓 AI 能夠在其中自主迭代、測試、修正，以達成特定目標。



AI Agent 團隊合作


PDCA


是一種持續改善的循環管理模型，
透過計畫、執行、檢核、行動四個階段，不斷優化流程與達成目標。




人類團隊合作










Human-in-the-Loop

Micro-Management !!



Human-on-the-Loop




AI Agents for Design, Verification, Test, Collaboration..

~~Human-in-the-Loop~~~~Micro-Management !!~~



Human-on-the-Loop



AI Management

AI 管理學

AI時代的科技管理與企業管理

協同 AI 與員工達到更高計畫組織成效

AI 計畫/組織的

執行流程、績效量測、資源調配、效率提升、
安全控管、衝突協調、緊急狀況處理

AI Agents for Design, Verification, Test, Collaboration..

~~Human-in-the-Loop~~

~~Micro-Management !!~~



人工智慧運算 七層架構：AI 不同的成長演進機制

AI 應用

Layer 7

應用層 Application Layer

在實際的應用場景與世界互動中，自我遞歸的智慧提升

AI 代理功能

Layer 6

協調層 Orchestrator Layer

能力擴增在 Agent 團隊的組織運作 (Orchestration)

Layer 5

代理層 Agent Layer

能力強化在 AI Agent 各種工程技術

Harness Engineering
Loop Engineering
Graph Engineering
Long-Horizon Loop Engr.

神經網路功能

Layer 4

情境層 Context Layer

知識組織在 結構化的情境記憶體 (Context Memory)

Tokens

Layer 3

神經網路層 Neural Network Layer

知識學習在 神經網路的參數 (Parameter)

運算基礎架構

Layer 2

連結層 Link Layer

Layer 1

實體層 Physical Layer

人工智慧的發展：Narrow AI, AGI , ASI to UAI

Narrow AI

窄域人工智慧

【專精單一領域】
在特定任務中表現優異。
依賴特定數據與訓練，
無法處理預期之外的問題。

Here
We
Are

AGI Artificial General Intelligence

一般性通用人工智慧

【人類水準】
指在絕大多數具有經濟
價值的任務上，
達到與普通成年人相當
或中位數水準的 AI

ASI Artificial Superintelligence

超級智慧

【超越人類】
指在幾乎所有領域都
顯著超越人類大腦極限、
甚至超越人類全體智慧
結晶的系統

UAI Universal AI

終極人工智慧

【理論數學上限】
在任何可計算環境中，
數學上被證明能做出
最優決策的理論極限。

pathways for
AI development
in a
post-AGI
world:

❑ 計算、模型和數據的擴展

Scaling of compute, models & data

❑ 演算法範式轉變

Algorithmic paradigm shifts

❑ 遞歸（自我）改進


Recursive (self-) improvement

❑ 透過群體智能體建構人工智慧

ASI via group agent formation

Ref: Google DeepMind

AI 佔據整體科技產業產值 41%，半導體產業 30% (2026)



* 科技產業, AI 與半導體產值採用 Gartner 數據. GDP 為 IMF數據。AI 對 GDP 增加比例為 PWC預估。

* Gartner (2026/4) 全球半導體收入 2026 預測 Logic (Non-memory) 686.9 Bn / Memory 633.3 Bn，總和 1,320.3 Bn。其中 30% 為 AI 半導體，約 386 Bn。

群益金鼎證券股份有限公司 ethan.zhuang@capital.com.tw 於 2026/08/21 07:43:37 下載

©DIGITIMES版權所有，本資料僅供報名學員學習使用，未經授權轉載、散布或商業利用，將追究法律責任