

Citi | 全球半導體 | Kimi K3 : Another Jevon's

Paradox | 2026 年 7 月 20 日

核心重點

- Moonshot AI（月之暗面）發布 Kimi K3，採用 2.8 兆（2.8T）參數，為目前全球最大 Open-weight（開放權重）大型語言模型。
- 完整模型權重預計於 2026 年 7 月 27 日公開。
- Citi 認為，Kimi K3 的推出將再次帶動 Jevons' Paradox（傑文斯悖論），即模型效率提升反而刺激更多 AI 應用，使整體算力與記憶體需求增加。
- 維持對 Memory（記憶體）產業正向看法，尤其看好：
 - Server DDR5
 - Enterprise SSD（eSSD）

Kimi K3 技術架構

- 採用三大核心架構：
 - Kimi Delta Attention（KDA）
 - Hybrid Linear Attention
 - 大幅降低 100 萬 Token Context Window 成本
 - Attention Residuals（AttnRes）
 - 可跨模型深度擷取 Representation
 - 提升推論品質

- Stable LatentMoE
 - 採 Extreme MoE Sparsity
 - 每個 Token 僅啟動 896 位 Experts 中的 16 位
 - 提高訓練效率

商業競爭力

- 相較目前 Frontier Closed Models
 - Token 成本更低
 - Benchmark 表現更佳
- 適合：
 - Long-horizon AI Agent
 - Agentic Workflow
 - 多步驟推理
 - 長上下文任務
- 因模型規模龐大
 - 需 Multi-node Cluster
 - Supernode 架構超過 64 張 GPU

Citi 觀點：Jevons' Paradox 再次發生

- 雖然模型效率持續提升
- Token 成本下降
- 推論效率改善

但：

- AI 使用量將同步快速增加
- AI Agent 數量增加
- Token 生成量快速提升
- 最終 Memory 需求仍持續增加

因此：

- 整體 Server Memory 需求不減反增
- 記憶體需求增速將高於效率提升速度

對記憶體需求影響

Kimi K3 對記憶體需求影響

項目	影響
Server DDR5	正向增加需求
Enterprise SSD（eSSD）	正向增加需求
KV Cache 容量	明顯增加
AI Agent Token	快速成長
Commodity Memory	持續受惠

KV Cache 影響

- Kimi K3 模型更大

- KV Cache Footprint 同步放大
- 推論過程需更多：
 - DRAM
 - DDR5
 - eSSD
- 即使 Inference Efficiency 改善
- KV Cache 容量增加仍將推升記憶體需求

與 DeepSeek 相似之處

- 採用類似 Distillation（模型蒸餾）概念
- 訓練效率大幅提升
- 推論成本降低
- 促進更多企業導入 AI
- 再次形成 Jevons' Paradox

AI Agent 發展

由於 Kimi K3 屬於：

- Open-weight Model
- 可供開發者自由部署
- 容易建立各類 AI Agent

因此預期：

- AI Agent 數量快速增加
- Token Consumption 持續成長
- Memory 需求同步提高

投資觀點

- 維持 Memory 產業正向看法
- Kimi K3 將成為記憶體需求的新催化劑
- 看好：
 - Server DDR5
 - Enterprise SSD
 - Commodity Memory
- AI Agent 普及將帶動長期 Token 需求成長
- Memory 供應商可望持續受惠於 AI 推論與 KV Cache 需求增加。